

SÍLABO 2025-1

I. INFORMACIÓN GENERAL

Nombre del curso : **Data Science con Python**

Profesor del curso : Alexander Quispe Rojas

Email : aw.quispero@up.edu.pe, alexander.quispe@pucp.edu.pe

Prácticas : Paul Melo Ramos

Email: PA.MeloR@up.edu.pe

Horas Teoría : 2 Horas, Martes 7:30-9:20am

Horas Práctica : 2 Horas, Miércoles 7:30-9:20am

Requisito : Econometría 1

Asesoría : <https://calendly.com/alexander-quispe>

II. SUMILLA

Este curso ofrece una visión integral del ecosistema de Python, abordando desde la gestión de proyectos con Git y GitHub hasta la aplicación de técnicas de recolección y análisis de datos. Se introduce la sintaxis y los fundamentos del lenguaje, la creación de funciones y clases, y el uso de librerías para web scraping (incluyendo Selenium) y consumo de APIs. Además, se profundiza en la visualización de datos con Seaborn y en el análisis geoespacial a través de mapas estáticos y dinámicos. Finalmente, se presenta una introducción a los modelos de lenguaje de gran tamaño (LLMs) dentro del ámbito de la Inteligencia Artificial, con el fin de mostrar sus aplicaciones y alcances éticos.

III. PRESENTACIÓN

El propósito de este curso es capacitar a las y los estudiantes en el uso de Python como una herramienta versátil para el desarrollo de proyectos y la resolución de problemas complejos que involucran datos. Iniciaremos con una descripción de qué significa la ciencia de datos y su flujo de trabajo. Con este punto de partida, pasaremos a introducir el control de versiones mediante Git y GitHub, lo que garantizará la colaboración ordenada y la trazabilidad de los cambios. A continuación, exploraremos los aspectos fundamentales del lenguaje Python, desde la sintaxis básica hasta estructuras de programación basada en objetos, con el objetivo de fomentar la escritura de código modular y escalable.

En la siguiente etapa, nos adentraremos en la recopilación y manipulación de datos, abarcando técnicas de web scraping con Selenium para sitios dinámicos, así como la comunicación con diferentes servicios a través de APIs. Estos conocimientos se complementarán con la construcción de visualizaciones efectivas usando Seaborn, promoviendo la buena presentación y el análisis estadístico de la información.

El curso incluye también un bloque dedicado al análisis geoespacial y al manejo de datos vectoriales y raster, esenciales para trabajar con información de ubicación y cartografía. Finalmente, se introducirá el concepto de inteligencia artificial aplicada a Python, enfocándonos en los Modelos de Lenguaje de gran tamaño (LLMs) para mostrar sus posibilidades y limitaciones. Este enfoque integral prepara a las y los participantes para afrontar retos en la industria y la investigación, dotándoles de competencias sólidas que abarcan desde el control de versiones y la programación de alto nivel, hasta el análisis de datos y las primeras incursiones en la IA moderna.

IV. RESULTADOS DE APRENDIZAJE

Al finalizar el curso, las y los estudiantes serán capaces de:

- Aplicar el flujo de trabajo para la ciencia de datos, utilizando Git y GitHub para gestionar versiones de proyectos de manera colaborativa y ordenada.
- Dominar los fundamentos de Python, incluyendo la sintaxis básica, la creación de funciones y el uso de clases, a fin de estructurar y organizar de forma eficiente sus programas.
- Extraer datos de sitios web mediante técnicas de web scraping y Selenium, y consumir datos de múltiples fuentes a través de APIs.
- Crear visualizaciones efectivas con seaborn para el análisis y la comunicación de información.
- Realizar análisis geoespaciales con datos vectoriales y raster, generando mapas estáticos y dinámicos para resolver problemas de localización y representar información geográfica de manera clara.
- Acercarse a los conceptos fundamentales de la Inteligencia Artificial y, en particular, a los Modelos de Lenguaje de gran tamaño (LLMs), entendiendo sus aplicaciones prácticas y consideraciones éticas.

De esta forma, las y los participantes obtendrán tanto la base conceptual como las herramientas de implementación necesarias para abordar proyectos en diversos ámbitos, desde la ciencia de datos hasta el desarrollo de software y la incipiente área de la IA.

V. CONTENIDO DEL CURSO

1. Introducción a la Ciencia de Datos

Visión general de la disciplina de ciencia de datos, sus fases fundamentales y la relación con áreas como la estadística y la inteligencia artificial. Se revisarán casos de uso y el flujo de trabajo típico en proyectos de ciencia de datos.

2. Control de versiones con Git y GitHub

Fundamentos del control de versiones y su importancia en proyectos colaborativos. Creación y administración de repositorios, ramas, merges y resolución de conflictos, así como la integración con GitHub para la comunicación y despliegue de proyectos.

3. Introducción a Python

Presentación de la sintaxis básica del lenguaje, instalación y configuración del entorno de trabajo. Tipos de datos (numéricos, cadenas, listas, diccionarios) y estructuras de control (condicionales y bucles).

4. Funciones y Clases en Python

Organización del código mediante la definición de funciones y la aplicación de principios de la programación orientada a objetos. Creación de clases, constructores, atributos y métodos.

5. Procesamiento de datos en Python

Uso de librerías como pandas y NumPy para la manipulación, limpieza y transformación de datos. Exploración de formatos de datos y preparación de conjuntos de entrenamiento.

6. Visualización de Gráficos: matplotlib y seaborn

Generación de representaciones gráficas eficaces para el análisis y la comunicación de resultados. Configuración de gráficos, estilos y patrones de diseño con matplotlib y seaborn

7. Web Scraping 1: Selenium

Extracción de información de sitios web dinámicos utilizando Selenium. Creación de scripts para la automatización de navegadores, manejo de tiempo de espera y captcha, y técnicas de localización de elementos.

8. Web Scraping 2: APIs

Introducción a las Interfaces de Programación de Aplicaciones y su papel en la obtención de datos. Consumo de APIs en Python, manejo de formatos de respuesta (JSON, XML).

9. Análisis geoespacial 1: mapas estáticos

Principios de la georreferenciación y uso de librerías para la visualización de mapas estáticos. Creación y personalización de mapas, además de la manipulación de datos espaciales (shapefiles, GeoJSON).

10. Análisis geoespacial 2: mapas dinámicos

Extensión de las capacidades de visualización geoespacial mediante herramientas y librerías que permitan la generación de mapas interactivos. Integración de capas, controles y animaciones para presentar datos geográficos de manera dinámica.

11. Datos raster

Fundamentos del manejo de datos en formato raster (imágenes satelitales y modelos de elevación). Lectura, procesamiento y visualización de este tipo de archivos, así como su combinación con datos vectoriales.

12. Introducción al trabajo con LLMs: Ingeniería de instrucciones

Conceptos básicos sobre la configuración y personalización de modelos de lenguaje. Diseño de prompts y estrategias para guiar la generación de texto hacia la obtención de resultados específicos.

13. Introducción al trabajo con LLMs: Generación aumentada con recuperación de información

Uso de técnicas de recuperación de datos en combinación con la generación automática de texto. Implementación de métodos que permiten al modelo consultar repositorios de información para enriquecer la salida generada.

14. Fundamentos de la computación acelerada con CUDA Python: Introducción al modelo de programación y paralelismo

Exploración de los principios básicos de CUDA y cómo se integran con Python mediante bibliotecas como Numba o CuPy. Implementación de kernels simples para operaciones paralelas, entendiendo la arquitectura de la GPU y los conceptos de hilos, bloques y grids. Aplicación de aceleración en tareas

computacionalmente intensivas como transformaciones de arrays o cálculos numéricos.

15. Fundamentos de la computación acelerada con CUDA Python: Optimización y uso eficiente de la memoria

Desarrollo de estrategias para optimizar el rendimiento de código en GPU, incluyendo el uso eficiente de la memoria compartida, constante y global. Comparación de tiempos de ejecución entre CPU y GPU para diferentes tipos de tareas. Aplicación de técnicas de profiling para identificar cuellos de botella y mejorar la eficiencia computacional en proyectos de ciencia de datos.

VI. METODOLOGÍA

Clases virtuales (2 horas semanales) y sesiones prácticas (2 horas semanales)

VII. EVALUACIÓN

Se evaluará la asistencia y participación en las clases. Tendremos en total 6 prácticas calificadas de las cuales vamos a eliminar la nota más baja y la vamos a reemplazar con la nota más alta.

TIPO DE EVALUACIÓN	CANTIDAD	PESO TOTAL (EN %)
Asistencia/Participación	1	10
Práctica 1	1	15
Práctica 2	1	15
Práctica 3	1	15
Práctica 4	1	15
Práctica 5	1	15
Práctica 6	1	15

VIII. BIBLIOGRAFÍA

Békés, G., & Kézdi, G. (2021). *Data Analysis for Business, Economics, and Policy*. Cambridge University Press.

Chacon, S., & Straub, B. (2014). *Pro Git* (2nd ed.). Apress. <https://git-scm.com/book/en/v2>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2023). *Introduction to Statistical Learning: With Applications in Python*. Springer.

LangChain. (s.f.). *Conceptual Guide*. <https://python.langchain.com/docs/concepts/>

IX. CRONOGRAMA

Semana	TEMA/CONTENIDOS	
Nº	Sección del curso	Fecha sugerida de práctica calificada
1	Introducción a Python	
2	Web Scraping 1: Selenium	Práctica 1 – miércoles 2 de abril
3	Web Scraping 2: APIs	
4	Visualización de Gráficos: matplotlib y seaborn	Práctica 2 – miércoles 16 de abril
5	Análisis geoespacial 1: mapas estáticos	
6	Análisis geoespacial 2: mapas dinámicos	
7	Datos raster	Práctica 3 – miércoles 30 de abril
8	Dashboards - Streamlit	
9	Exámenes parciales (5 al 10 de mayo)	
10	Introducción al trabajo con LLMs: Ingeniería de instrucciones	Práctica 4 – miércoles 11 de junio
11	Introducción al trabajo con LLMs: Generación aumentada con recuperación de información	
12	Agents	Práctica 5 – miércoles 25 de junio
13	Parallel Computing - CUDA 1	
14	Parallel Computing - CUDA 2	Práctica 6 – miércoles 9 de julio
15	Exámenes finales (1 al 5 de agosto)	