

SÍLABO 2026-I

I. INFORMACIÓN GENERAL

Nombre del curso: Métodos Avanzados en Deep Learning

Programa: Maestría en Economía Aplicada (MECA) – Universidad del Pacífico

Ciclo: MECA 2 – Ciclo 4 – Electivo 3

Profesor del curso: Alexander Quispe Rojas

Email: aw.quispero@up.edu.pe, aquisper@caltech.edu

Horas: 24 horas (10 sesiones virtuales)

Créditos: 1.5

Modalidad: Todas las clases virtuales

Requisito: Data Science con Python (o conocimientos equivalentes de Python y manejo de datos)

Asesoría: <https://calendly.com/alexander-quispe>

II. SUMILLA

Este curso ofrece una introducción rigurosa y aplicada a los métodos de deep learning, diseñado específicamente para profesionales y estudiantes de economía aplicada. Se cubren los fundamentos teóricos de las neural networks —desde el perceptron y backpropagation hasta las arquitecturas modernas como Convolutional Neural Networks (CNNs), Recurrent Neural Networks (RNNs), attention mechanisms y Transformers— con énfasis en su implementación práctica en Python usando PyTorch. El curso culmina con el estudio de Large Language Models (LLMs) y foundation models, explorando sus aplicaciones en el análisis económico, la investigación y la formulación de políticas públicas.

III. PRESENTACIÓN

El deep learning ha transformado múltiples disciplinas, y la economía no es la excepción. Desde el análisis de texto en discursos de bancos centrales hasta la predicción de variables macroeconómicas con datos no estructurados, las técnicas de aprendizaje profundo ofrecen herramientas poderosas para los economistas aplicados.

Este curso parte de los fundamentos matemáticos del deep learning —perceptrons, activation functions, loss functions y el algoritmo de backpropagation— y avanza progresivamente hacia arquitecturas más sofisticadas. Se estudiarán las Convolutional Neural Networks para el procesamiento de imágenes y datos espaciales, los word embeddings (Word2Vec) y las Recurrent Neural Networks para datos secuenciales, los mecanismos de attention y self-attention, y la arquitectura Transformer que sustenta los language models modernos.

La parte final del curso se dedica a los foundation models (LLMs, CLIP, DINO) y sus aplicaciones en economía, incluyendo sentiment analysis de textos económicos, la extracción de información de documentos de política, y el uso de pretrained models para tareas de investigación.

Todas las implementaciones se realizarán en Python, utilizando PyTorch y Google Colab, lo que permite a los estudiantes experimentar con GPUs sin necesidad de infraestructura local.

IV. RESULTADOS DE APRENDIZAJE

Al finalizar el curso, las y los estudiantes serán capaces de:

- Comprender los fundamentos matemáticos de las neural networks, incluyendo activation functions, loss functions, backpropagation y stochastic gradient descent.
- Implementar feedforward neural networks, Convolutional Neural Networks y Recurrent Neural Networks en PyTorch para resolver problemas de classification y regression.
- Explicar el funcionamiento de los mecanismos de attention, self-attention y la arquitectura Transformer.
- Utilizar Large Language Models (LLMs) y pretrained models para tareas de análisis de texto y datos económicos.
- Aplicar técnicas de transfer learning y fine-tuning a problemas relevantes en economía aplicada.
- Evaluar críticamente las posibilidades, limitaciones y consideraciones éticas del uso de deep learning en la investigación económica y la política pública.

V. CONTENIDO DEL CURSO

1. Introducción al Deep Learning y Perceptrons

Visión general del deep learning, su historia y su relevancia para la economía aplicada. El perceptron como unidad básica de computación. Classification y regression. Introducción al entorno de trabajo: Python, PyTorch y Google Colab.

2. Non-linearities, Loss Functions, Backpropagation y Gradient Descent

Activation functions (sigmoid, tanh, ReLU). Loss functions para regression (MSE) y classification (cross-entropy). El algoritmo de backpropagation. Gradient descent y sus variantes.

3. Training de Neural Networks: SGD, Batching, Regularization y Generalization

Stochastic Gradient Descent (SGD), mini-batches y momentum. Regularization (L1, L2, dropout). Overfitting y técnicas de generalization. El Universal Approximation Theorem y el valor de la profundidad. Introducción a GPUs y computación paralela.

4. Convolutional Neural Networks (CNNs)

Motivación: procesamiento de imágenes y datos espaciales. Operación de convolution, pooling y arquitecturas clásicas (LeNet, AlexNet, ResNet). Aplicaciones en economía: análisis de imágenes satelitales, detección de patrones en datos geoespaciales.

5. Word Embeddings (Word2Vec) y Recurrent Neural Networks (RNNs)

Representación vectorial de palabras: Word2Vec (Skip-gram, CBOW). Recurrent Neural Networks: arquitectura básica, LSTM y GRU. Language models. Aplicaciones en economía: análisis de time series y procesamiento de texto económico.

6. Attention y Self-Attention Mechanisms

Limitaciones de las RNNs para secuencias largas. Attention mechanism: queries, keys y values. Self-attention. Multi-head attention. De attention a las arquitecturas modernas.

7. Transformers

La arquitectura Transformer: encoder y decoder. Positional embeddings. Layer normalization y residual connections. Por qué los Transformers reemplazaron a las RNNs. Implementación práctica.

8. Large Language Models (LLMs) y aplicaciones en economía

De BERT a GPT: la evolución de los LLMs. Pretraining y fine-tuning. Prompt engineering. Aplicaciones en economía: sentiment analysis de minutas de bancos centrales, clasificación de textos de política económica, extracción de información de documentos regulatorios.

9. Foundation Models: CLIP, DINO y Transfer Learning

Foundation models y el paradigma de pretraining. CLIP: conectando texto e imágenes. DINO: self-supervised learning. Vision Transformers (ViTs). Transfer learning y fine-tuning para tareas económicas. Supervision y data curation.

VI. METODOLOGÍA

Clases virtuales sincrónicas con un enfoque teórico-práctico. Cada sesión combina la presentación de conceptos teóricos con ejercicios prácticos de implementación en Python (PyTorch) utilizando Google Colab. Se fomenta la discusión de aplicaciones relevantes para la economía aplicada y la participación activa de los estudiantes.

Los materiales del curso (slides, notebooks, datos) estarán disponibles en un repositorio de GitHub.

VII. EVALUACIÓN

Se evaluará la asistencia, participación en clases, 4 prácticas calificadas (homeworks) y un examen final oral. Cada práctica consiste en un trabajo para la casa donde los estudiantes deberán subir los datasets utilizados y el script (código) correspondiente.

Tipo de evaluación	Cantidad	Peso total (%)
Asistencia / Participación	1	10
Práctica 1: Feedforward Neural Networks	1	15
Práctica 2: CNNs y RNNs	1	15
Práctica 3: Transformers y NLP	1	15
Práctica 4: LLMs y Foundation Models	1	15
Examen final oral	1	30

Nota: Cada práctica se entrega subiendo los datasets y el script (código) utilizado.

Examen final oral

El examen final oral se realizará de manera individual por Zoom el viernes 22 de mayo. Cada estudiante dispondrá de **10 minutos**, durante los cuales el profesor realizará **2 preguntas** relacionadas con cualquier tema del curso. Las preguntas pueden incluir:

- Preguntas conceptuales sobre los temas cubiertos en el curso (e.g., “Explica cómo funciona self-attention”).
- La resolución de un ejercicio matemático breve, de complejidad moderada, resoluble en menos de 10 minutos (e.g., calcular un paso de backpropagation, derivar una loss function, aplicar gradient descent).
- La interpretación de un fragmento de código (screenshot) donde el estudiante deberá explicar qué hace el código, identificar la arquitectura utilizada, o predecir el output esperado.

El objetivo es verificar la comprensión conceptual y práctica de los contenidos cubiertos a lo largo de las 9 sesiones. No se permite el uso de LLMs, apuntes ni ningún material de apoyo durante el examen.

Política de uso de LLMs y herramientas de IA

Los estudiantes pueden y se les anima a utilizar cualquier Large Language Model (ChatGPT, Claude, Gemini, etc.) como herramienta de apoyo para el desarrollo de las prácticas. Se recomienda fuertemente el uso de **Claude Code** (suscripción de \$20 USD/mes), que permite asistencia directa en la escritura, debugging y ejecución de código desde la terminal.

Sin embargo, los estudiantes deben comprender el código que entregan y ser capaces de explicar su funcionamiento. El uso de LLMs es una herramienta de productividad, no un sustituto del aprendizaje.

Google Colab

Para la ejecución de los modelos se utilizará Google Colab, que ofrece acceso gratuito a GPUs. Se recomienda considerar la suscripción a **Colab Pro** (\$10 USD/mes) o **Colab Pro+** (\$50 USD/mes) para obtener mayor tiempo de GPU y recursos de cómputo, especialmente para las prácticas 3 y 4 que involucran modelos más grandes. Google ofrece descuentos educativos que pueden ser consultados en su plataforma.

Política de entregas tardías

- Por cada día de atraso en la entrega de una práctica, se descontarán **2 puntos** (sobre 20) de la nota obtenida.
- Después de **3 días** de atraso, la práctica **no será aceptada** y recibirá una nota de cero.
- No se aceptarán excepciones salvo casos debidamente justificados y comunicados con anticipación al profesor.

VIII. CRONOGRAMA

Sesión	Tema / Contenido	Fecha y horario	Evaluación
1	Introducción al Deep Learning y Perceptrons	Lunes 13 de abril, 7:30–10:00 pm (2.5 h)	
2	Non-linearities, Loss Functions, Backpropagation y Gradient Descent	Viernes 17 de abril, 7:30–10:00 pm (2.5 h)	
3	Training: SGD, Regularization y Generalization	Lunes 20 de abril, 7:30–10:00 pm (2.5 h)	Entrega Práctica 1 – Domingo 27 de abril
4	Convolutional Neural Networks (CNNs)	Sábado 25 de abril, 8:30–11:00 am (2.5 h)	
5	Word Embeddings (Word2Vec) y Recurrent Neural Networks (RNNs)	Lunes 27 de abril, 7:30–10:00 pm (2.5 h)	Entrega Práctica 2 – Domingo 4 de mayo
6	Attention y Self-Attention Mechanisms	Sábado 2 de mayo, 8:30–11:00 am (2.5 h)	
7	Transformers	Sábado 9 de mayo, 8:30–11:00 pm (2.5 h)	Entrega Práctica 3 – Domingo 11 de mayo
8	Large Language Models (LLMs) y aplicaciones en economía	Sábado 16 de mayo, 8:30–11:00 am (2.5 h)	
9	Foundation Models: CLIP, DINO, Transfer Learning	Lunes 18 de mayo, 7:30–9:30 pm (2 h)	Entrega Práctica 4 – Lunes 18 de mayo
10	Examen final oral (individual, 10 min por estudiante, 2 preguntas)	Viernes 22 de mayo, 7:30–9:30 pm (2 h)	Examen final oral

IX. DESCRIPCIÓN DE LAS PRÁCTICAS CALIFICADAS

Práctica 1: Feedforward Neural Networks

Implementación de una feedforward neural network en PyTorch para un problema de classification o regression con datos económicos. Los estudiantes deberán entrenar el modelo, ajustar hyperparameters (learning rate, número de layers, regularization) y reportar resultados con métricas de evaluación apropiadas. **Entregable:** dataset y script (.py o .ipynb).

Práctica 2: CNNs y RNNs aplicados a datos económicos

Aplicación de Convolutional Neural Networks a datos de imágenes (por ejemplo, imágenes satelitales para predicción económica) o Recurrent Neural Networks a datos secuenciales (time series económicas). Se evaluará la correcta implementación de la arquitectura y la interpretación de resultados. **Entregable:** dataset y script (.py o .ipynb).

Práctica 3: Transformers y Natural Language Processing

Uso de un modelo basado en Transformers (por ejemplo, BERT o un modelo similar) para una tarea de NLP relevante en economía: sentiment analysis de textos financieros, clasificación de documentos de política, o extracción de información de reportes económicos. **Entregable:** dataset y script (.py o .ipynb).

Práctica 4: LLMs y Foundation Models

Aplicación de Large Language Models o foundation models a un problema de análisis económico. Los estudiantes deberán subir el dataset utilizado y el script con la implementación completa, incluyendo preprocessing, modelo y evaluación de resultados. **Entregable:** dataset y script (.py o .ipynb).

X. BIBLIOGRAFÍA

Textos principales

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. <https://www.deeplearningbook.org/>

Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2023). *Dive into Deep Learning*. Cambridge University Press. <https://d2l.ai/>

Textos complementarios

Jurafsky, D., & Martin, J. H. (2024). *Speech and Language Processing* (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT*.

Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., ... & Sutskever, I. (2021). Learning Transferable Visual Models From Natural Language Supervision (CLIP). *Proceedings of ICML*.

Aplicaciones de deep learning en economía

Athey, S., & Imbens, G. W. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*, 11, 685–725.

Gentzkow, M., Kelly, B., & Taddy, M. (2019). Text as Data. *Journal of Economic Literature*, 57(3), 535–574.

Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining Satellite Imagery and Machine Learning to Predict Poverty. *Science*, 353(6301), 790–794.

Hansen, S., & McMahon, M. (2016). Shocking Language: Understanding the Macroeconomic Effects of Central Bank Communication. *Journal of International Economics*, 99, S114–S133.

Dell, M., & Olken, B. A. (2020). The Development Effects of the Extractive Colonial Economy: The Dutch Cultivation System in Java. *The Review of Economic Studies*, 87(1), 164–203.

Recursos en línea

PyTorch Documentation. <https://pytorch.org/docs/stable/index.html>

Google Colab. <https://colab.research.google.com/>

Karpathy, A. (2015). The Unreasonable Effectiveness of Recurrent Neural Networks. <https://karpathy.github.io/2015/05/21/rnn-effectiveness/>